



UNIVERSITÀ
DI TORINO

Dipartimento di Informatica

Tecnologie del Linguaggio Naturale

Parte III, Luigi Di Caro

Federico Chirco

Anno Accademico 2024/2025

Riduzione dell'ambiguità semantica tramite pseudoword multilingue

1. Introduzione

La polisemia, ovvero la presenza di più significati associati a una stessa parola, rappresenta una delle principali fonti di ambiguità nel linguaggio naturale e costituisce una sfida per numerosi task di Natural Language Processing (NLP). Nonostante i progressi dei modelli contestuali, le risorse lessicali rimangono fortemente ambigue e strutturate in modo non uniforme tra le lingue.

Una caratteristica rilevante delle lingue naturali è che **le distinzioni semantiche non vengono codificate in maniera omogenea**: una parola polisemica in una lingua può corrispondere a termini meno ambigui in un'altra, oppure viceversa. Questa variazione cross-lingua può essere sfruttata per ridurre l'ambiguità semantica individuando significati stabili e condivisi tra lingue diverse. Risorse come **WordNet** e **Open Multilingual WordNet (OMW)**, basate su synset indipendenti dalla lingua, forniscono un contesto ideale per questo tipo di analisi.

In questo lavoro si propone un approccio cross-lingua alla riduzione dell'ambiguità basato sulla costruzione di **pseudoword**, ovvero unità lessicali artificiali ottenute accoppiando parole di lingue diverse. Data una parola x in una lingua sorgente L_1 e una parola y in una lingua di estensione L_2 , la pseudoword $x-y$ è associata all'insieme dei significati condivisi tra le due parole, che risulta tipicamente meno ambiguo rispetto agli inventari semantici originali.

L'obiettivo del progetto è progettare una **pipeline automatica** per la generazione di pseudoword multilingue e analizzarne l'efficacia in termini di riduzione dell'ambiguità. Oltre a una metrica standard basata sulla diminuzione del numero di sensi, è introdotta una misura complementare che favorisce una **riduzione bilanciata dell'ambiguità tra le lingue**, meglio allineata con l'idea di un'unità semantica interlingua. I risultati sperimentali sono effettuati su coppie di sostantivi **italiano-francese** e mostrano che l'approccio proposto consente una significativa riduzione dell'ambiguità lessicale e produce rappresentazioni semantiche più stabili per task downstream.

2 Progettazione e Metodo

L'approccio seguito si basa sull'osservazione che la polisemia lessicale varia tra le lingue e che tale variazione può essere sfruttata per ridurre l'ambiguità semantica. A partire da questa intuizione, si è progettata una pipeline per la costruzione automatica di **pseudoword multilingue**, utilizzando risorse lessicali strutturate.

2.1 Risorse lessicali

Come risorsa di base viene utilizzato **WordNet**, nella sua estensione multilingue **Open Multilingual WordNet (OMW)**. WordNet organizza i significati lessicali in **synset**, ovvero insiemi di sensi semanticamente equivalenti e indipendenti dalla lingua, collegati a lemmi appartenenti a lingue diverse. Questa struttura consente di confrontare direttamente gli inventari semantici di parole appartenenti a lingue differenti.

Nel presente lavoro l'analisi è stata condotta su coppie di sostantivi **italiano-francese**, selezionati a partire dall'inventario completo dei lemmi disponibili in OMW.

2.2 Formalizzazione del problema

Sia x una parola appartenente alla lingua sorgente L_1 e sia y una parola appartenente alla lingua di estensione L_2 . Si definisce:

- S_x : l'insieme dei synset associati a x in L_1
- S_y : l'insieme dei synset associati a y in L_2

A partire da tali insiemi, la pseudoword x - y viene associata all'insieme dei significati condivisi:

$$S_{x-y} = S_x \cap S_y$$

Per costruzione, risulta:

$$|S_{x-y}| \leq \min(|S_x|, |S_y|)$$

e nella maggior parte dei casi l'intersezione è strettamente più piccola rispetto agli inventari semantici originali, consentendo una riduzione dell'ambiguità.

2.3 Strategia di generazione delle pseudoword

La generazione delle pseudoword avviene in modo automatico seguendo i seguenti passaggi:

1. per ogni lemma x in L_1 , si recupera l'insieme S_x dei synset associati;
2. per ciascun synset in S_x , si estraggono i lemmi y appartenenti alla lingua L_2 ;
3. per ogni coppia candidata (x, y) , si calcola l'intersezione $S_x \cap S_y$;
4. la pseudoword x - y viene mantenuta solo se l'intersezione contiene almeno un numero minimo di sensi condivisi.

Al fine di ridurre rumore e casi patologici presenti nelle risorse lessicali, vengono applicati ulteriori filtri lessicali, tra cui l'eliminazione di lemmi artificiali o non linguistici e l'imposizione di limiti massimi sull'ambiguità dei termini nella lingua di estensione.

2.4 Metriche di valutazione

Per valutare l'efficacia della riduzione dell'ambiguità si utilizza inizialmente una metrica standard di **Ambiguity Reduction (AR)**, definita come:

$$AR(x, y) = \frac{|S_x| + |S_y| - 2|S_{x-y}|}{|S_x| + |S_y|}$$

Tale misura quantifica la riduzione complessiva del numero di sensi rispetto agli inventari originali. Tuttavia, essa non distingue tra casi in cui la riduzione è distribuita in modo equilibrato tra le lingue e casi in cui è concentrata prevalentemente in una sola lingua.

Per questo motivo viene introdotta una metrica complementare, denominata **Joint Reduction Score (JRS)**, che misura la riduzione relativa dell'ambiguità in entrambe le lingue:

$$JRS(x, y) = \frac{|S_x| - |S_{x-y}|}{|S_x|} \cdot \frac{|S_y| - |S_{x-y}|}{|S_y|}$$

Questa metrica penalizza le pseudoword caratterizzate da riduzioni fortemente sbilanciate e favorisce quelle che rappresentano una riduzione congiunta e bilanciata dell'ambiguità semantica.

3 Implementazione

L'approccio descritto è stato implementato in Python utilizzando la libreria **NLTK** per l'accesso a WordNet e alla sua estensione multilingue Open Multilingual WordNet. Al fine di garantire efficienza computazionale, gli inventari semantici sono stati **indicizzati** preventivamente costruendo, *per ciascuna lingua considerata*, una **mappatura tra lemmi e insiemi di synset associati**.

La pipeline di generazione delle pseudoword è organizzata in moduli distinti. In una prima fase, vengono selezionati i **lemmi** della lingua sorgente caratterizzati da un grado minimo di polisemia e filtrati tramite vincoli ortografici e lessicali, così da escludere artefatti presenti nella risorsa. Successivamente, per ciascun lemma sorgente, vengono individuati i **candidati nella lingua di estensione** attraverso i synset condivisi, e per ogni coppia viene calcolata l'intersezione degli inventari semantici.

Durante la generazione vengono applicati ulteriori criteri di filtraggio, tra cui la restrizione a una specifica categoria grammaticale (nel presente lavoro, i **sostantivi**), un **numero minimo di sensi condivisi** e un limite massimo all'ambiguità dei lemmi nella lingua di estensione. Tali vincoli consentono di ridurre il rumore e di ottenere pseudoword semanticamente più stabili.

Le metriche di valutazione, inclusa la misura standard di **Ambiguity Reduction** e la metrica proposta **Joint Reduction Score**, sono state calcolate automaticamente per ciascuna pseudoword generata. I risultati sono stati infine aggregati e analizzati tramite statistiche descrittive e visualizzazioni, consentendo un confronto diretto tra le diverse misure di riduzione dell'ambiguità.

4 Risultati

Applicando i vincoli di filtraggio descritti nella sezione precedente (categoria grammaticale, numero minimo di sensi condivisi e limiti di ambiguità), sono state generate complessivamente **467 pseudoword**.

4.1 Riduzione dell'ambiguità

L'analisi quantitativa mostra che i lemmi sorgente presentano un'elevata polisemia, con un'ambiguità media pari a **9.24 synset** per l'italiano e **9.82 synset** per il francese. Le pseudoword ottenute risultano invece associate in media a **3.15 synset**, evidenziando una **riduzione significativa dell'ambiguità semantica**.




Figura 1. Ambiguità: parola sorgente vs pseudoword

Il grafico in Figura 1 confronta la distribuzione dell'ambiguità dei lemmi sorgente $|S_x|$ con quella delle pseudoword $|S_{x \cap y}|$.

Si osserva che i lemmi sorgente presentano tipicamente un'elevata polisemia, con una distribuzione concentrata tra 8 e 15 synset. Al contrario, le pseudoword mostrano una distribuzione fortemente spostata verso valori più bassi, prevalentemente compresi tra 1 e 4 synset.

Questo risultato conferma che la costruzione delle pseudoword produce una **riduzione sostanziale dell'ambiguità lessicale**, comprimendo l'inventario semantico in modo sistematico. Allo stesso tempo, la presenza di pseudoword con più di un senso condiviso indica che la riduzione non si limita a selezionare un singolo significato, ma preserva insiemi semantici coerenti e riutilizzabili.

4.2 Confronto tra Ambiguity Reduction e Joint Reduction Score

La riduzione dell'ambiguità è stata valutata mediante la metrica standard di **Ambiguity Reduction (AR)** e mediante la metrica proposta **Joint Reduction Score (JRS)**. AR presenta un valore medio pari a **0.66** (mediana **0.69**), suggerendo una forte riduzione complessiva del numero di sensi. Tuttavia, come illustrato in Figura 2, tale metrica tende a concentrarsi su valori elevati anche in presenza di riduzioni fortemente sbilanciate tra le lingue.




Figura 2. Distribuzione di Ambiguity Reduction (AR) e Joint Reduction Score (JRS)

La distribuzione di JRS risulta invece più selettiva, con valori mediamente più bassi (**0.39**, mediana **0.41**), riflettendo la capacità della metrica di penalizzare i casi in cui la riduzione dell'ambiguità è ottenuta prevalentemente in una sola lingua.

Il confronto diretto tra AR e JRS (Figura 3) mostra una **correlazione positiva** tra le due misure, ma anche una significativa **dispersione**: pseudoword con AR elevato possono corrispondere a valori di JRS sensibilmente inferiori, indicando una riduzione sbilanciata.

Questi risultati suggeriscono che una riduzione puramente quantitativa dell'ambiguità non è sempre indicativa della qualità della pseudoword come unità semantica interlingua e che l'uso di una metrica congiunta fornisce una valutazione più informativa.




Figura 3. Relazione tra AR e JRS

4.3 Esempi di pseudoword

La Figura 4 riporta alcuni esempi rappresentativi delle pseudoword con i valori più elevati di JRS. Tali coppie mostrano una riduzione bilanciata dell'ambiguità e una chiara coerenza semantica.

	pseudoword	S _x	S _y	S _x ∩S _y	AR	jrs
29	gioco-partie	14	24	2	0.894737	0.785714
11	campo-domaine	15	18	2	0.878788	0.770370
25	modello-forme	14	19	2	0.878788	0.766917
49	passo-passage	13	19	2	0.875000	0.757085
0	fine-mort	16	14	2	0.866667	0.750000

Figura 4. Esempi rappresentativi delle pseudowords

In questi casi, l'intersezione dei sensi cattura concetti astratti e stabili (ad esempio *parte di un gioco*, *ambito disciplinare*, *fase di un processo*), mostrando come le pseudoword non si limitino a fissare un singolo significato, ma costruiscano unità semantiche condivise e generalizzabili.

Nel complesso, i risultati dimostrano che la costruzione di pseudoword consente una riduzione efficace dell'ambiguità lessicale e che la metrica JRS permette di distinguere tra riduzioni meramente quantitative e riduzioni semanticamente più robuste.

5 Conclusioni

Sfruttando la variazione nella codifica della polisemia tra lingue diverse, le pseudoword consentono di ottenere rappresentazioni semantiche più specifiche e stabili rispetto ai termini originali, riducendo in modo significativo lo spazio delle ipotesi semantiche.

L'analisi sperimentale su coppie di sostantivi italiano-francese mostra che l'ambiguità media dei termini può essere drasticamente ridotta tramite l'intersezione degli inventari semantici. Tuttavia, i risultati evidenziano anche come una riduzione puramente quantitativa del numero di sensi non sia sempre indicativa della qualità della pseudoword. In particolare, la metrica proposta Joint Reduction Score si è dimostrata utile nel discriminare tra riduzioni sbilanciate e riduzioni congiunte dell'ambiguità, meglio allineate con l'idea di un'unità semantica interlingua condivisa.

Il lavoro presenta alcune limitazioni. In primo luogo, l'approccio dipende dalla copertura e dalla qualità delle risorse lessicali utilizzate, nonché dalla presenza di rumore e artefatti in Open Multilingual WordNet. Inoltre, la valutazione si basa esclusivamente su metriche intrinseche di ambiguità, senza un'integrazione diretta in task downstream come WSD o MT.

Come sviluppi futuri, si prevede l'estensione dell'approccio a ulteriori lingue e categorie grammaticali, nonché l'esplorazione di strategie più fini di aggregazione dei sensi condivisi. Un ulteriore passo consisterà nell'integrazione delle pseudoword in sistemi di disambiguazione o traduzione automatica, al fine di valutarne l'impatto diretto sulle prestazioni in scenari applicativi reali.