



UNIVERSITÀ
DI TORINO

Dipartimento di Informatica

Tecnologie del Linguaggio Naturale

Parte III, Luigi Di Caro

Federico Chirco

Anno Accademico 2024/2025

ES1 | Legare risorse eterogenee: WordNet + embeddings

1. Introduzione

L'obiettivo dell'esercitazione è **legare risorse eterogenee**, combinando:

- **WordNet**, risorsa simbolica che fornisce i possibili significati di una parola (synset, glosse, esempi, relazioni);
- **embeddings distribuzionali** (FastText pre-addestrato), che rappresentano le parole come vettori densi e permettono confronti tramite similarità.

Il task scelto è la **Word Sense Disambiguation (WSD)**: data una frase e una parola ambigua, selezionare il synset di WordNet più coerente con il contesto.

2. Metodo

2.1 Preprocessing dei token

Il codice normalizza i token tramite `normalize_token()`:

- converte in minuscolo;
- rimuove caratteri speciali;
- mantiene lettere, numeri, underscore e apostrofo.

Questo serve a far combaciare meglio i token con le chiavi nel vocabolario degli embeddings.

2.2 Costruzione del vettore di un synset (synset embedding)

Per ogni synset WordNet viene costruito un vettore con `synset_embedding()` combinando tre componenti:

1. **Lemma embedding**

Si prendono i lemma del synset e, se multi-parola, si dividono in parti.

Il vettore del synset parte come media dei vettori dei lemma disponibili.

2. Gloss embedding

La glossa (definizione in WordNet) viene tokenizzata e trasformata in un vettore medio. Questo vettore viene sommato con un peso (`gloss_weight`, default 0.6).

3. Examples embedding

Gli esempi d'uso del synset vengono concatenati, tokenizzati e mediati in un vettore. Anche questo viene aggiunto con un peso (`examples_weight`, default 0.4).

In sintesi:

$$\text{synset_vec} = \text{lemma_vec} + \alpha \cdot \text{gloss_vec} + \beta \cdot \text{examples_vec}$$

dove α e β sono i pesi scelti.

2.3 Costruzione del vettore di contesto (context embedding)

Con `context_embedding()` si rappresenta la frase tramite la **media dei vettori delle parole della frase**, con due scelte:

- si **rimuove la parola target** (per evitare che “domini” il contesto);
- si possono rimuovere le **stopwords** inglesi.

In questo modo il vettore rappresenta “di cosa parla” la frase **attorno** alla parola ambigua.

2.4 Decisione WSD (scelta del synset migliore)

Con `disambiguate_wordnet_wsd()`:

1. si estraggono i synset candidati di WordNet per la parola (eventualmente filtrando per POS: NOUN/VERB/...);
 2. si calcola la cosine similarity tra:
 - vettore del contesto
 - vettore di ciascun synset
 3. si sceglie il synset con score massimo e si restituisce anche una top-k classifica.
-

3. Analisi dei risultati

L'algoritmo di Word Sense Disambiguation è stato testato su un insieme di frasi contenenti parole fortemente polisemiche (*bank*, *bat*, *plant*, ...).

Per ogni frase è stato selezionato il synset WordNet con **massima similarità coseno** rispetto al vettore di contesto.

3.1 Esempio di un caso correttamente disambiguato

- *I went to the **bank** to deposit money* (in figura).
Il sistema seleziona **savings_bank.n.02**, riconoscendo correttamente il dominio finanziario della frase.

Sentence: I went to the bank to deposit money.
Target: bank

Best synset: savings_bank.n.02

Definition: a container (usually with a slot in the top) for keeping money at home

Top candidates:

savings_bank.n.02	score=0.7971	def=a container (usually with a slot in the top) for keeping money at home
depository_financial_institution.n.01	score=0.7594	def=a financial institution that accepts deposits and channels
bank.n.06	score=0.7229	def=the funds held by a gambling house or the dealer in some gambling games
bank.n.09	score=0.7157	def=a building in which the business of banking transacted
bank.n.01	score=0.7072	def=sloping land (especially the slope beside a body of water)

- The river overflowed the **bank** after the storm.
Il synset **bank.n.01** (argine del fiume) risulta il più simile al contesto.

In entrambi i casi la distinzione tra **senso finanziario** e **senso geografico** viene catturata correttamente, grazie a parole di contesto come *deposit*, *money*, *river* e *storm*.

3.2 Esempio di un caso problematico

plant (pianta botanica)

- I watered the **plant** on the windowsill.
Il sistema seleziona **plant.n.04** ("oggetto piantato segretamente"), invece del senso botanico.

Anche in questo caso il contesto domestico è riconosciuto, ma:

- la parola *plant* resta ambigua;
- le glosse WordNet per *plant* includono sensi molto diversi ma lessicalmente sovrapposti;
- la similarità semantica tra glosse porta a una scelta non corretta.

3.3 Osservazioni generali

Dai risultati emergono alcune considerazioni chiave:

- Il metodo funziona bene quando:
 - il contesto è ricco e specifico;
 - i sensi sono semanticamente lontani (es. *bank* fiume vs banca).
- Mostra difficoltà quando:
 - i sensi sono molto simili o appartengono allo stesso dominio;
 - le definizioni WordNet contengono parole generiche;
 - la rappresentazione del contesto è breve o basata su semplici medie di embedding.

I risultati mostrano come l'integrazione tra WordNet ed embeddings distribuzionali consenta una disambiguazione semantica efficace in molti casi, pur evidenziando i limiti di approcci basati su rappresentazioni mediate e non contestuali.

ES2 | Analisi di similarità lessicale e semantica tra definizioni

1. Introduzione

L'obiettivo di questa esercitazione è valutare la **coerenza interna delle definizioni** associate a uno stesso concetto, confrontandole sia dal punto di vista **lessicale** sia dal punto di vista **semantico**.

L'idea è verificare:

- se definizioni diverse dello stesso concetto usano **parole simili**
- se, anche quando le parole cambiano, il **significato rimane coerente**

Per fare ciò vengono introdotte due misure complementari:

- **simlex**: similarità lessicale
- **simsem**: similarità semantica

I risultati vengono poi aggregati per categoria concettuale:

- **CG**: Concreto Generico
 - **CS**: Concreto Specifico
 - **AG**: Astratto Generico
 - **AS**: Astratto Specifico
-

2. Similarità lessicale (simlex)

2.1 Preprocessing

Prima di calcolare la similarità lessicale, le definizioni vengono preprocessate:

1. conversione in minuscolo
2. tokenizzazione tramite espressioni regolari
3. rimozione delle **stopword italiane**
4. applicazione dello **stemming** (SnowballStemmer)

Questo riduce la variabilità superficiale delle parole e rende il confronto più robusto.

2.2 Misura di similarità

La similarità lessicale tra due definizioni è calcolata tramite la **Jaccard similarity**:

$$\text{Jaccard}(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

dove A e B sono gli insiemi dei token delle due definizioni.

- valore vicino a **1** → definizioni molto simili nel lessico
- valore vicino a **0** → definizioni con parole molto diverse

Per ogni termine viene calcolata la **media della simlex** su tutte le coppie possibili di definizioni.

3. Similarità semantica (simsem)

3.1 Sentence embeddings

Per la similarità semantica viene utilizzato un modello di **sentence embeddings pre-addestrato**: paraphrase-multilingual-MiniLM-L12-v2. Questo modello:

- supporta l'italiano
- mappa frasi semanticamente simili in vettori vicini nello spazio vettoriale

Ogni definizione viene quindi convertita in un vettore embedding.

3.2 Misura di similarità

La similarità semantica tra due definizioni è calcolata tramite **cosine similarity**:

$$\cos(\theta) = \frac{\vec{a} \cdot \vec{b}}{\|\vec{a}\| \|\vec{b}\|}$$

- valore vicino a **1** → definizioni semanticamente molto simili
- valore più basso → differenza di significato

Anche in questo caso, per ogni termine viene calcolata la **media della simsem** su tutte le coppie di definizioni.

4. Analisi dei risultati

La Tabella seguente riporta i valori medi di similarità lessicale (**simlex**) e semantica (**simsem**) aggregati per categoria concettuale:

Categoria	Termine	simlex_mean	simsem_mean
AG	Pericolo	0.112	0.653
AS	Euristica	0.042	0.454
CG	Pantalone	0.186	0.659
CS	Microscopio	0.154	0.633

4.1 Similarità lessicale (simlex)

I valori di **simlex** risultano complessivamente **bassi in tutte le categorie**. Questo indica che definizioni diverse tendono a utilizzare **parole differenti**, anche quando descrivono lo stesso concetto.

- Le categorie astratte (**AS – Euristica** con 0.042 e **AG – Pericolo** con 0.112) mostrano valori di simlex più bassi
- Le categorie **concrete** (**CG – Pantalone** con 0.186 e **CS – Microscopio** con 0.154) mostrano dei valori di simlex leggermente più alti, coerentemente con il fatto che i concetti concreti sono più facili da descrivere con un vocabolario condiviso

4.2 Similarità semantica (simsem)

I valori di **simsem** sono sensibilmente più elevati rispetto a quelli di **simlex**, confermando che le definizioni, pur usando parole diverse, tendono a esprimere **contenuti semantici coerenti**.

- **AS – Euristica** registra il valore più basso di **simsem** (0.454), indicando una maggiore variabilità interpretativa
- I restanti concetti concreti (**CG – Pantalone** con 0.659 e **CS – Microscopio** con 0.633) e il concetto astratto generale (**AG – Pericolo** con 0.653) indicano invece un'elevata coerenza di significato tra le definizioni

Questi risultati suggeriscono che la *specificità* e l'*astrattezza* del concetto influiscono negativamente sulla coerenza semantica delle definizioni.

4.3 Confronto tra **simlex** e **simsem**

Il confronto tra le due misure evidenzia un fenomeno chiave: **la similarità semantica è sistematicamente più alta della similarità lessicale in tutte le categorie**.

Le definizioni di **concetti astratti** tendono a:

- usare lessico più vario (**simlex** ↓),
- mantenere comunque coerenza concettuale (**simsem** ↑).

I **concetti concreti** risultano:

- più stabili lessicalmente,
- facilmente riconoscibili anche a livello distribuzionale.

Questo indica che:

- le definizioni condividono il **significato**, anche quando il **lessico differisce**
- le misure basate su embeddings riescono a catturare relazioni semantiche che non emergono dal semplice overlap di parole

In particolare, il divario tra **simlex** e **simsem** per **Euristica (AS)** è importante, confermando che per concetti astratti e specialistici l'uso di modelli semantici è essenziale.

ES3 | Content-to-form: dalla definizione al synset WordNet

1. Introduzione

L'obiettivo di questa esercitazione è affrontare il problema **content-to-form**, ovvero il processo inverso rispetto alla consultazione tradizionale di un dizionario.

Dato un **concetto descritto tramite una definizione testuale**, si vuole individuare il **termine o il synset di riferimento** all'interno di una risorsa lessicale strutturata, in questo caso **WordNet**.

Il task si colloca nel contesto della **ricerca onomasiologica**, dove non si parte dalla parola ma dal contenuto concettuale, e mira a valutare se e in che misura sia possibile automatizzare un compito tipicamente svolto da linguisti e lessicografi.

2. Risorse e dati utilizzati

Sono state usate le seguenti **risorse linguistiche**:

- **WordNet** come risorsa lessicale di riferimento
 - **Open Multilingual WordNet (OMW)** per accedere ai lemma italiani associati ai synset
 - **Sentence embedding multilingue** (paraphrase-multilingual-MiniLM-L12-v2) per il confronto semantico tra testi in lingue diverse
-

3. Approccio metodologico

L'approccio adottato combina **euristiche linguistiche** e **modelli distribuzionali**, articolandosi nelle seguenti fasi.

3.1 Estrazione del genus

Per ciascuna definizione viene estratto un **genus**, ovvero il concetto più generale che introduce la definizione (principio **genus-differentia**).

L'estrazione avviene tramite semplici euristiche basate su pattern ricorrenti nelle definizioni:

- "X è un/una Y ..."
- "Un/Una Y ..."

In assenza di tali pattern, viene utilizzata come fallback la prima parola significativa della definizione.

Questa fase ha lo scopo di **ridurre lo spazio di ricerca** su WordNet, evitando il confronto con l'intero inventario dei synset.

3.2 Selezione dei synset candidati

A partire dal genus estratto:

1. Si cercano i synset WordNet che contengono il genus come **lemma italiano** (tramite OMW)
2. In caso di fallimento, si utilizza il genus come lemma inglese
3. Dai synset trovati si costruisce una **chiusura sugli iponimi** (hyponyms), fino a una profondità massima prefissata (depth=2)

In questo modo si ottiene un insieme di **synset candidati semanticamente coerenti** con la definizione di partenza.

3.3 Rappresentazione semantica cross-lingual

Le definizioni sono in **italiano**, mentre le glosse di WordNet sono in **inglese**. Per rendere possibile il confronto, entrambe vengono proiettate nello **stesso spazio vettoriale multilingue** usando un modello Sentence-BERT.

Questo consente di calcolare una **similarità coseno** direttamente tra:

- embedding della definizione italiana
 - embedding della glossa inglese del synset
-

3.4 Scoring dei synset

Ogni synset candidato viene valutato tramite uno score composto da:

1. **Similarità semantica** tra definizione e glossa (cosine similarity)
2. **Bonus lessicale** (molto leggero) se uno dei lemma italiani del synset compare letteralmente nella definizione

Lo score finale è dato dalla somma di questi due contributi.

3.5 Valutazione

Per ciascuna definizione viene selezionato il **synset con lo score più alto**.

La predizione viene considerata **corretta** se il **termine italiano di riferimento** è presente tra i lemma italiani del synset selezionato. Questo criterio di valutazione è volutamente **rigido**, ma consente una verifica automatica e riproducibile.

4. Analisi dei risultati

Dall'analisi degli output emerge che il sistema riesce nella maggior parte dei casi a individuare correttamente **l'area semantica di appartenenza del termine**, anche quando non seleziona il synset esatto. I candidati proposti risultano infatti spesso semanticamente coerenti con la definizione, pur non corrispondendo al termine target.

Questo comportamento evidenzia che il modello di embeddings cattura efficacemente la **similarità discorsiva** tra definizione e glossa WordNet, ma non sempre garantisce una distinzione sufficientemente fine tra concetti ontologicamente vicini.

4.1 Effetto del genus e degli iponimi

Il ruolo del *genus* è centrale nel ridurre lo spazio di ricerca. Una volta estratto, il sistema esplora l'albero di WordNet verso il basso (iponimi) fino a una profondità prefissata (depth = 2). Ciò consente di includere sia i figli diretti del genus sia i "nipoti" concettuali.

Quando il genus è **ben allineato semanticamente** alla definizione, questo meccanismo funziona correttamente.

Al contrario, quando il genus è **troppo generico o semanticamente ambiguo**, l'insieme dei candidati risulta rumoroso. Termini come *capo*, *strumento*, *dispositivo* o *criterio* sono altamente polisemici in WordNet e conducono a rami ontologici molto diversi tra loro. In questi casi, l'esplorazione degli iponimi include concetti non pertinenti al dominio della definizione, compromettendo la qualità della selezione finale.

4.2 Analisi di casi rappresentativi

Nel caso del termine **pantalone**, le definizioni analizzate conducono spesso a genus come "indumento" o "capo". A partire da tali genus, WordNet include numerosi iponimi appartenenti alla categoria generale dell'abbigliamento (ad esempio *shirt*, *leotard*, *body stocking*, *trouser*). Il sistema seleziona talvolta concetti errati ma semanticamente affini, come *leotard*, poiché la glossa inglese enfatizza proprietà condivise ("copre le gambe", "indumento") che risultano molto simili alla definizione italiana. Questo fenomeno mostra come il modello privilegi la similarità semantica globale rispetto alla corretta collocazione tassonomica.

Nel caso di **microscopio**, il sistema individua correttamente il dominio degli strumenti ottici o scientifici, proponendo candidati come *magnifier*, *binoculars* o *optical instrument*. Anche in questo caso, tuttavia, la distinzione funzionale tra strumenti diversi non emerge con sufficiente forza dalle glosse WordNet, portando a una selezione non sempre corretta del synset specifico.

Diversamente, per concetti astratti come **pericolo**, il sistema mostra prestazioni migliori. Le definizioni di tali concetti sono meno legate a proprietà fisiche e più a stati o condizioni, e ciò favorisce un migliore allineamento tra definizione e glossa, riducendo la confusione tra iponimi.

Il termine **euristica** rappresenta invece un caso limite: si tratta di un concetto disciplinare e metateorico che WordNet modella solo indirettamente. Di conseguenza, il sistema individua synset semanticamente affini (ad esempio *rule*, *technique*, *scheme*), ma non riesce a recuperare un concetto che corrisponda pienamente al significato specialistico del termine.

5. Conclusioni

Nel complesso, il sistema dimostra una buona capacità di **localizzare il dominio concettuale corretto**, ma una precisione limitata nella selezione del synset esatto. L'approccio risulta quindi efficace come **meccanismo di filtraggio semantico**, ma non sempre sufficiente come metodo di disambiguazione ontologica completa.

I risultati suggeriscono che ulteriori miglioramenti dovrebbero concentrarsi sulla disambiguazione del genus e sull'introduzione di vincoli semantici più specifici, piuttosto che su un semplice affinamento della misura di similarità.

ES4 | Clustering e Topic Modelling con modelli di embedding

1. Introduzione

L'obiettivo dell'esercitazione è applicare tecniche di **clustering semantico e topic modelling** basate su **embedding distribuzionali** a un dataset testuale di grandi dimensioni, al fine di individuare automaticamente gruppi tematici coerenti.

In particolare, l'esperimento si colloca nel paradigma **content-based**, dove i documenti vengono rappresentati in uno spazio vettoriale continuo e successivamente raggruppati in base alla loro vicinanza semantica.

2. Dataset utilizzato

Per l'esperimento è stato utilizzato il dataset **AG News**, una collezione di articoli giornalistici in lingua inglese, comunemente impiegata come benchmark per compiti di classificazione e clustering testuale.

Ogni documento appartiene originariamente a una delle quattro macro-categorie (World, Sports, Business, Sci/Tech), ma tali etichette **non vengono utilizzate durante il clustering**, rendendo l'approccio completamente non supervisionato.

Per motivi di efficienza computazionale, il dataset è stato ridotto tramite campionamento casuale a **20.000 documenti**, quantità comunque sufficiente a garantire una buona varietà tematica.

3. Pipeline di modellazione

L'approccio adottato si basa su **BERTopic**, un framework che combina modelli di linguaggio neurale con tecniche di clustering e riduzione dimensionale.

La pipeline seguita è composta dai seguenti passaggi:

1. Embedding dei documenti

Ogni articolo viene trasformato in un vettore numerico tramite il modello **GTE-small**, un modello di sentence embeddings addestrato su grandi quantità di testo generale.

Questo consente di rappresentare ogni documento come un punto in uno spazio semantico ad alta dimensionalità.

2. Riduzione dimensionale (UMAP)

Gli embeddings vengono ridotti dimensionalmente mediante **UMAP**, che preserva le relazioni di vicinanza locali e rende possibile sia il clustering che la visualizzazione.

3. Clustering (HDBSCAN)

Il clustering vero e proprio è effettuato con **HDBSCAN**, un algoritmo density-based in grado di:

- individuare automaticamente il numero di cluster,
- gestire rumore e outlier,
- produrre cluster di dimensioni variabili.

4. Estrazione dei topic

Per ciascun cluster, BERTopic individua le parole chiave più rappresentative tramite una combinazione di **TF-IDF e frequenza locale**, usando un CountVectorizer con stopword inglesi rimosse.

Il parametro `min_topic_size=50` è stato utilizzato per evitare la creazione di topic troppo piccoli e poco interpretabili.

4. Analisi dei risultati e visualizzazioni


Dall'output emerge che il modello ha individuato un numero consistente di topic semanticamente coerenti. I topic più frequenti risultano chiaramente interpretabili e riconducibili a macro-aree tipiche del dataset AG News, come:

- sport (es. NFL, baseball, calcio europeo, Olimpiadi),
- politica (Bush, Kerry, Medio Oriente),
- tecnologia (Microsoft, software, Linux),
- economia (profit, earnings, sales),
- scienza e spazio (NASA, moon, Mars).

Una parte significativa dei documenti (circa 4.500 su 20.000) è assegnata al **topic -1**, che rappresenta gli *outlier*. Questo comportamento è atteso nel contesto di BERTopic e HDBSCAN: i documenti molto generici, ambigui o difficilmente raggruppabili vengono esclusi dai cluster principali.

4.1 Barchart delle parole chiave

Il grafico a barre delle parole chiave mostra, per i topic più rilevanti, i termini che maggiormente contribuiscono alla loro definizione semantica.



Questa visualizzazione è utile per interpretare il significato di ciascun cluster.

4.2 Visualizzazione UMAP dei documenti

Rappresenta ogni documento in uno spazio bidimensionale, colorato in base al topic assegnato.

Documents and Topics




La visualizzazione UMAP dei documenti mostra una struttura spaziale ben organizzata:

- i documenti appartenenti allo stesso topic tendono a formare **cluster compatti**;
- topic semanticamente affini risultano **vicini nello spazio**, mentre topic molto diversi sono ben separati.

Questo conferma che la rappresentazione embedding + riduzione dimensionale preserva in modo efficace le relazioni semantiche tra i testi.

4.3 Mappa delle distanze tra topic

La **Intertopic Distance Map** visualizza le relazioni tra i topic a livello globale, evidenziando quali temi sono semanticamente più vicini o più distanti tra loro.



5. Conclusioni

L'esperimento dimostra che l'uso combinato di **sentence embeddings**, **riduzione dimensionale** e **clustering non supervisionato** consente di estrarre automaticamente strutture tematiche da grandi collezioni testuali.

BERTopic si rivela uno strumento efficace per il topic modeling moderno, soprattutto in contesti dove i documenti sono lunghi e semanticamente complessi, come gli articoli di news.

ES5 | LLM e Prompting

1. Introduzione

L'obiettivo di questa esercitazione è esplorare l'uso di **Large Language Models (LLM)** all'interno di semplici task di **labeling e classificazione lessicale**, valutando l'impatto delle scelte di modello e delle strategie di prompting.

In particolare, l'esercizio si articola in due sotto-attività:

- **5.1 – Topic modelling:** assegnare una **label semantica descrittiva** a ciascun topic ottenuto nel laboratorio n.4 (Topic Modelling su AG News).
- **5.2 – Reverse dictionary:** indovinare il termine corretto a partire dalle definizioni del dataset dataset_definizioni_TLN_25.

L'obiettivo non è ottenere prestazioni ottimali in senso assoluto, ma analizzare **come e quanto un LLM riesca a svolgere questi compiti in funzione del prompt e del contesto fornito**.

2. Topic modelling

Per il task di topic labeling è stato utilizzato un modello LLM instruction-tuned, **Qwen/Qwen2.5-1.5B-Instruct**, interrogato tramite una pipeline di generazione testuale.

In input al modello viene fornita, per ciascun topic, una lista di **keyword rappresentative** estratte dal modello BERTopic dell'esercitazione precedente (es: Topic 0: [profit, sales, fullquote, percent, stores, earnings]).

Il prompt richiede esplicitamente la produzione di **una singola etichetta concisa**, che riassume semanticamente il contenuto del topic.

2.1 Strategia di prompting

Il prompt utilizzato richiede al modello di:

- interpretare le keyword come appartenenti a un topic di un *news dataset*;
- generare **una singola label**, concisa e descrittiva;
- evitare output lunghi o spiegazioni.

“““I will provide you with a list of keywords associated with a specific topic from a news dataset. Your task is to provide a single, concise Category Label that best describes the topic. Keywords: {keywords} Category Label:”””

2.2 Analisi dei risultati

Le etichette generate risultano complessivamente **coerenti e semanticamente corrette**.

```
Topic 0: [profit, sales, fullquote, percent, stores, earnings]
--> LABEL GENERATA: Financial News

Topic 1: [sox, red, yankees, series, baseball, league]
--> LABEL GENERATA: Baseball

Topic 2: [champions, england, league, arsenal, test, cup]
--> LABEL GENERATA: Football (Soccer) League

Topic 3: [microsoft, linux, ibm, software, intel, source]
--> LABEL GENERATA: Operating Systems and Software
```

Questo esperimento mostra come un LLM, anche di dimensioni relativamente contenute, sia in grado di svolgere efficacemente un task di **topic summarization** quando:

- il contesto è ben delimitato (lista di keyword)
- l'output richiesto è breve e chiaramente specificato

Il task di labeling risulta quindi **particolarmente adatto** all'uso di LLM, con risultati robusti anche senza prompt complessi.

3. Identificazione dei termini a partire dalle definizioni

Nel secondo task, il modello viene utilizzato come **dizionario inverso**: data una definizione in linguaggio naturale, deve restituire il termine corretto. Le definizioni utilizzate sono quelle delle esercitazioni di laboratorio n.2 e n.3, e i termini da indovinare (Pantalone, Microscopio, Pericolo, Euristicica) costituiscono il *gold standard*.

3.1 Strategie di prompting

V1 – Zero-shot

La prima strategia utilizza un prompt minimale, che richiede al modello di restituire direttamente il termine corretto a partire dalla definizione, imponendo forti vincoli sull'output (una sola parola, in italiano, lemma canonico). Questa strategia sfrutta esclusivamente le capacità generalistiche del modello, senza esempi o contesto aggiuntivo.

“““Sei un classificatore lessicale in italiano. Data una definizione, restituisci il termine corretto.

REGOLE DI OUTPUT:

- Scrivi SOLO il termine, in ITALIANO.
- UNA sola e singola parola, singolare, senza spazi né punteggiatura.
- Non usare inglese.
- Usa la forma più comune e canonica (lemma).

Definizione: {definition}

Termine:”””

V2 – Few-shot + contesto semantico

La seconda strategia introduce esempi espliciti (few-shot) e vincoli semantici più forti nel prompt. In particolare:

- vengono forniti esempi rappresentativi per ciascun termine;
- si guida il modello a distinguere concetti vicini (es. *euristica* vs *algoritmo*);
- si riducono errori morfologici e di interpretazione.

Questo approccio rende il prompt più informativo e orienta il modello verso il lessico atteso.

“““Sei un classificatore lessicale in italiano.

Dato una definizione, restituisci il termine corretto.

REGOLE DI OUTPUT:

- Scrivi SOLO il termine, in ITALIANO.
- UNA sola e singola parola, singolare, senza spazi né punteggiatura.
- Non usare inglese.
- Usa la forma più comune e canonica (lemma).
- Se predici il termine 'Pantaloni', usa invece il singolare 'Pantalone'.

- Se la definizione descrive una regola pratica per risolvere problemi/decidere rapidamente -> usa il lemma standard.

Esempi:

Definizione: Strumento ottico che ingrandisce oggetti molto piccoli.

Termine: Microscopio

Definizione: Possibilità di subire un danno o una minaccia.

Termine: Pericolo

Definizione: Strategia pratica non garantita ottima per risolvere un problema.

Termine: Euristicica

Definizione: Indumento che copre la parte inferiore del corpo e le gambe.

Termine: Pantalone

Definizione: {definition}

Termine: """"

3.2 Post-processing

Per rendere la valutazione più robusta e ridurre errori puramente formali, è stata inoltre introdotta una fase di **normalizzazione dell'output**, per gestire:

- **decoding controllato**: viene considerata esclusivamente la **prima parola** dell'output generato dal modello, eliminando eventuali spiegazioni indesiderate e output multi-parola (es. "metodo stocastico" → "metodo").
 - **variazioni morfologiche** (es. *pantaloni* → *pantalone*, *euristiche* → *euristica*)
-

3.3 Risultati

I risultati quantitativi mostrano un **miglioramento** netto passando dal prompt zero-shot al few-shot:

- **V1 – Zero-shot: 56** risposte corrette su 153 → **36.60%**

Gli errori più frequenti sono dovuti a:

- uso di sinonimi (*rischio* invece di *pericolo*);
 - iperonimi o concetti correlati (*metodo*, *ricerca*);
 - ambiguità semantica nelle definizioni.
- **V2 – Few-shot: 77** risposte corrette su 153 → **50.33%**

Rispetto alla strategia zero-shot, si osserva:

- un miglioramento netto dell'accuratezza (+13.7%);
- una maggiore stabilità sulle definizioni più ambigue;
- una riduzione degli errori morfologici.

Il termine più problematico rimane **Euristica**, spesso confuso con iperonimi o concetti affini come *metodo*, *strategia* o *regola*.

3.4 Analisi degli errori

Gli errori osservati seguono pattern ricorrenti:

- Produzione di termini semanticamente corretti ma **non coincidenti con il gold label**
 - **Astrazione eccessiva** nei concetti astratti
 - **Preferenza per iperonimi** invece del lemma specifico
-

4. Conclusioni

L'esercitazione mostra chiaramente che:

- Gli LLM sono **molto efficaci** per task di labeling e sintesi semantica (5.1).
- Nel task di reverse dictionary (5.2), le prestazioni dipendono fortemente dal **prompt design**.
- L'uso di strategie di prompting più strutturate (few-shot) e di vincoli espliciti migliora sensibilmente i risultati, ma **non elimina del tutto le ambiguità**, soprattutto per concetti astratti.

Nel complesso, l'esperimento evidenzia come l'uso degli LLM in compiti linguistici "classici" conferma l'importanza di:

- progettare prompt adeguati al task;
- sperimentare iterativamente più strategie;
- affiancare il modello con semplici regole di post-processing.